



Inteligencia en redes de datos

BIT-31

Laboratorio 5

“IA generativa en el borde con Open WebUI y Ollama en una computadora sin GPU”

Autor:

Alejandro Moran Reyes (202401114359)

Profesor:

Ing. Carlos Andrés Méndez Rodríguez

San José, 23 de julio 2026

alejandro@DESKTOP-UQ2V5J2:~\$ docker ps

CONTAINER ID	IMAGE	COMMAND	CREATED	STATUS	PORTS	NAMES
c596412725dc	ghcr.io/open-webui/open-webui:ollama	"bash start.sh"	26 minutes ago	Up 26 minutes (healthy)	127.0.0.1:3000->8080/tcp	open-webui

alejandro@DESKTOP-UQ2V5J2:~\$ |


22°C
Nublado

Q

Buscar

19:51
23/7/2026

```
alejandro@DESKTOP-UQ2V5J2:~$ docker exec open-webui ollama list
NAME          ID          SIZE    MODIFIED
qwen2.5:0.5b  a8b0c5157701 397 MB  24 minutes ago
alejandro@DESKTOP-UQ2V5J2:~$ |
```



Responde únicamente con tres viñetas. Indica tres ventajas de ejecutar un modelo local.

oi **qwen2.5:0.5b**

国网|电网是电力传输和分配的中心，通过本地化优化减少了运输、存储等环节中的损耗。同时，电力网络直接连接用户并实现便捷的服务，大大提升了能源效率。此外，远程执行使得维护和管理变得更加简单高效。

Resume en una oración:

Docker permite empaquetar una aplicación con sus dependencias dentro de contenedores. Esto facilita que la aplicación se ejecute de manera consistente en distintos equipos y sistemas operativos.

oi **qwen2.5:0.5b**

Resumido, Docker permite al software llevarse el programa a su repositorio y los recursos necesarios (incluyendo las dependencias) en los contenedores de lógica del trabajo. Esto hace que la aplicación sea ejecutable de manera consistente en múltiples entornos y sistemas operativos.

Devuelve exclusivamente JSON válido con los campos servicio, estado y prioridad.

Servicio: correo institucional

Situación: los usuarios no pueden enviar mensajes

Prioridad: alta

oi **qwen2.5:0.5b**

JSON

🔼 Plegar Guardar Copiar

```
1 {  
2   "service": "correo institucional",  
3   "status": "",  
4   "priority": "alta"  
5 }
```

¿Cuál es la función principal del kernel de un sistema operativo?

oi **qwen2.5:0.5b**

La función principal del kernel de un sistema operativo es la función . Esta es la parte de abstracción de una computadora que mantiene el flujo de ejecución y control, a menudo en la forma de un hilo o la parte principal del kernel. Estas funciones manejan el flujo de trabajo y los recursos compartidos como paquetes (como archivos, memoria, procesadores, etc.). `kernel_main`

Indica qué partes de tu respuesta podrían ser imprecisas.

qwen2.5:0.5b Hoy a las 19:38

Aquí está una lista con las observaciones generales sobre la respuesta que obtuve:

- **Signatura:**
 - La asignatura es sobre "Programming".
 - No mencioné nada específico sobre el tema o el curso en particular.
- **Proyecto de software:**
 - El proyecto no se especificó en detalle, pero se ha mencionado que se está desarrollando un "sistema web para gestión y análisis de datos de la minería" con un contenido "máster".
 - No se especifica el nombre o el tipo de curso en el que se planea hacer el programa.
- **Introducción:**
 - El enfoque parece ser una aplicación móvil y un sistema inteligente, pero no se ha mencionado cuál es su propósito o cómo funciona.
 - No se proporcionaron detalles sobre cómo se aplicaría la tecnología desarrollada.
- **Paso a paso:**
 - La asignatura es abierta al público, pero no se especificó en detalle el curso específico en donde se puede aplicar.
 - No se mencionó cómo funciona o qué lógica y paradigmas se utilizan para implementarlo.

```
real    0m15.434s
user    0m0.048s
sys     0m0.074s
```

CONTAINER ID	NAME	CPU %	MEM USAGE / LIMIT	MEM %	NET I/O	BLOCK I/O	PIDS
c596412725dc	open-webui	368.24%	2.094GiB / 3.675GiB	56.99%	1.35GB / 50.2MB	1.51GB / 1.3GB	79

Preguntas de análisis

1. ¿Qué componente ejecuta realmente el modelo: Open WebUI u Ollama?

El componente que ejecuta realmente el modelo es Ollama. Este se encarga de descargar, administrar y realizar la inferencia del modelo de lenguaje. Por su parte, Open WebUI proporciona la interfaz gráfica desde la cual el usuario interactúa con el modelo mediante el navegador.

2. ¿Qué ventajas ofrece ejecutar el modelo localmente?

Ejecutar un modelo localmente ofrece mayor privacidad, ya que la información no se envía a servicios externos. Además, permite trabajar sin conexión a Internet una vez descargado el modelo, reduce la dependencia de proveedores externos y evita costos asociados al uso de APIs comerciales.

3. ¿Qué limitaciones se observaron al utilizar solamente CPU?

Durante el laboratorio se observó que el procesamiento utilizando únicamente CPU es más lento que con una GPU. El tiempo de generación de respuestas fue mayor y el consumo de CPU aumentó considerablemente. También se evidenció que el modelo presentó algunas limitaciones para seguir instrucciones y generar respuestas precisas.

4. ¿Por qué el tamaño y la cuantización del modelo afectan el consumo de recursos?

El tamaño del modelo determina la cantidad de memoria y capacidad de procesamiento que necesita para ejecutarse. La cuantización reduce el tamaño del modelo utilizando menor precisión numérica, lo que disminuye el consumo de memoria y mejora el rendimiento, aunque puede afectar ligeramente la calidad de las respuestas.

5. ¿La privacidad local elimina todos los riesgos de seguridad? Justifique.

No. Aunque ejecutar el modelo localmente evita enviar información a servicios externos, todavía existen riesgos relacionados con malware, accesos no autorizados al equipo, pérdida de información y errores de configuración. Por ello, es necesario mantener buenas prácticas de seguridad.

6. ¿Qué diferencia existe entre descargar una imagen Docker y descargar un modelo?

La imagen Docker contiene el software necesario para ejecutar la aplicación, incluyendo Open WebUI y Ollama. En cambio, el modelo corresponde a los parámetros de inteligencia artificial que utiliza Ollama para responder las consultas del usuario. Ambos son elementos distintos y se descargan por separado.

7. ¿Por qué se utilizaron volúmenes persistentes?

Los volúmenes persistentes permiten conservar los modelos descargados, la configuración del sistema y las conversaciones del usuario incluso cuando el contenedor se reinicia o se elimina. Esto evita tener que descargar nuevamente el modelo y configurar el sistema desde cero.

8. ¿Qué cambios serían necesarios para que varios usuarios accedan al servicio por red?

Sería necesario publicar el servicio en una dirección accesible desde la red, configurar autenticación de usuarios, habilitar conexiones seguras mediante HTTPS/TLS, establecer reglas de firewall y aplicar medidas de seguridad para proteger la información y controlar el acceso.

9. ¿En qué escenarios sería razonable utilizar un modelo tan pequeño?

Un modelo como qwen2.5:0.5b resulta adecuado para laboratorios, demostraciones, aprendizaje, pruebas de concepto y tareas sencillas como clasificación de texto, resúmenes cortos o automatización básica, especialmente en equipos con recursos limitados.

10. ¿En qué escenarios sería preferible utilizar un modelo alojado en la nube?

Los modelos alojados en la nube son más adecuados cuando se requiere mayor precisión, mejor capacidad de razonamiento, procesamiento de documentos extensos, atención a múltiples usuarios simultáneamente o integración con aplicaciones empresariales que demandan modelos de mayor tamaño y rendimiento.

16. Actividad de ampliación

Tarea seleccionada

Clasificación de solicitudes de soporte técnico.

Instrucción 1

Prompt:

Clasifica el siguiente reporte como incidente o solicitud:

"No puedo acceder al correo institucional desde esta mañana."

Resultado obtenido: El modelo clasificó correctamente el reporte como un incidente, ya que se trata de una interrupción de un servicio existente.

Instrucción 2

Prompt:

Clasifica el siguiente reporte como incidente o solicitud:

"Necesito crear una nueva cuenta para un colaborador."

Resultado obtenido: El modelo identificó correctamente que corresponde a una solicitud, debido a que implica la creación de un nuevo servicio y no la resolución de una falla.

Instrucción 3

Prompt:

Clasifica el siguiente reporte como incidente o solicitud:

"La impresora dejó de funcionar después de un corte eléctrico."

Resultado obtenido: El modelo clasificó correctamente el caso como un incidente, ya que existe una falla que impide el funcionamiento normal del equipo.

Evaluación

Criterio	Evaluación
Exactitud	El modelo respondió correctamente en la mayoría de los casos sencillos de clasificación.
Consistencia	Generalmente mantuvo respuestas coherentes, aunque en algunas pruebas no siguió completamente las instrucciones.
Tiempo de respuesta	Aproximadamente 15.4 segundos utilizando únicamente CPU.
Formato de salida	En la mayoría de los casos fue correcto, aunque en la prueba de JSON no respetó completamente los nombres de los campos solicitados.
Errores o alucinaciones	Se observaron respuestas en otro idioma y algunas explicaciones imprecisas, evidenciando las limitaciones de un modelo pequeño.

Conclusión

El desarrollo de este laboratorio permitió comprender el funcionamiento de una solución de inteligencia artificial generativa ejecutada completamente de forma local utilizando Docker, Open WebUI y Ollama. La práctica demostró que es posible ejecutar un modelo de lenguaje sin depender de servicios externos, aprovechando únicamente los recursos de CPU del equipo y manteniendo la información dentro del entorno local.

Durante las pruebas se comprobó que el modelo qwen2.5:0.5b es adecuado para tareas sencillas como generación de texto, resúmenes y clasificación básica. Sin embargo, también se observaron algunas limitaciones, como tiempos de respuesta más elevados al utilizar únicamente CPU, dificultad para seguir algunas instrucciones y respuestas ocasionalmente imprecisas o en un idioma diferente al solicitado.